



Universidade de São Paulo
Escola de Artes, Ciências e Humanidades
Graduação em Sistemas de Informação

Fernanda Moraes Bernardo

Estimação da quantidade de carboidratos de alimentos a partir de imagens bidimensionais

São Paulo

2015

Fernanda Moraes Bernardo

Estimação da quantidade de carboidratos de alimentos a partir de imagens bidimensionais

Relatório parcial de atividades de trabalho de conclusão de curso anual apresentado como parte dos requisitos necessários para cumprimento da disciplina ACH2017 – Projeto Supervisionado ou de Graduação I.

Orientador: Prof. Dr. Clodoaldo Aparecido de Moraes Lima

(Assinatura do orientador)

São Paulo

2015

Resumo

Atualmente, grande parte da população tem certa preocupação com a sua alimentação, principalmente com quantidades e valores nutricionais. Estimação da quantidade e valores nutricionais de uma porção de alimento é uma tarefa extremamente difícil, pois muitos alimentos têm variação na forma e aparência devido às condições de preparação da comida ou alimento. Tendo isto como objetivo, nesse trabalho será desenvolvido um estimador de carboidratos a partir de imagens bidimensionais visando ajudar diabéticos no seu dia a dia a cuidar da sua alimentação. Técnicas de segmentação, classificação de imagens e reconstrução 3D serão investigadas para que seja possível calcular a quantidade de cada alimento a partir de imagem. Com base nesta estimativa, será possível estimar a quantidade de carboidratos presente nesses alimentos.

Palavras Chaves

- Segmentação de imagem
- Classificação de imagem
- Técnicas de reconstrução 3D

Modalidade:

- (X) Relatório Parcial de Trabalho de Graduação Longo – 1 ano – individual
- () Relatório Parcial de Trabalho de Graduação Longo – 1 ano – em grupo

Apresentação do Problema

Atualmente, existe uma grande preocupação das pessoas relacionada à dieta, principalmente daquelas com doenças crônicas e outros problemas de saúde, como hipertensão, obesidade, diabetes, doenças cardíacas e câncer. A necessidade de métodos e ferramentas exatas para medir a quantidade de alimentos e nutrientes consumidos torna-se imperativo para a investigação epidemiológica e clínica, ligando dieta e doença. A avaliação da quantidade de alimentos que alguém ingere ao longo do dia fornece informações valiosas para o diagnóstico e tratamento destes problemas de saúde. Estimação da quantidade de alimentos em uma porção é uma tarefa extremamente difícil, pois muitos alimentos têm variação na forma e aparência devido às condições de preparação da comida ou alimento.

Alinhado a essa preocupação, existe um crescente avanço da tecnologia, principalmente no que diz respeito a smartphones. Com isso, muitas soluções foram criadas para estimação da quantidade de alimentos visando auxiliar as pessoas, tendo como foco a facilidade e a economia de tempo. Entre essas soluções, algumas são voltadas para ajudar no planejamento dos nutrientes consumidos durante o dia ou consultar a quantidade desses nutrientes em determinados alimentos.

Ferramentas capazes de estimar a quantidade de carboidratos a partir de imagens de alimentos são de grande importância para pessoas diabéticas. Isto evitaria com que as pessoas precisassem carregar tabelas contendo a quantidade de carboidratos para cada alimento. Além destas tabelas, as pessoas precisam estimar a quantidade de alimentos presente em cada porção para calcular a quantidade exata de carboidratos que irão ingerir. Há duas abordagens principais para estimar o valor nutricional a partir de imagens de alimentos. Uma é estimar a categoria dos alimentos e fornecer informação associada a categoria. A outra é estimar o valor nutricional a partir das características da imagem usando análise de regressão (SUDO et al., 2014; XU et al., 2013; POULADZADEH et al., 2014; KAGAYA et al., 2014; HE et al., 2013; KAWANO et al., 2013).

Visando auxiliar pessoas com diabetes, este trabalho irá desenvolver uma ferramenta capaz de estimar a quantidade de carboidratos a partir de imagens de alimentos superando o problema citado anteriormente quanto à variação de forma e aparência dos alimentos. De forma a atingir este objetivo serão investigadas técnicas de segmentação e classificação de imagens de forma a identificar alimentos em uma dada imagem. Após a identificação destes alimentos, técnicas de reconstrução 3D serão investigadas para a reconstrução dos alimentos no espaço tridimensional. Neste espaço, o volume ocupado por cada alimento será estimado e com base na densidade deste, será possível estimar a quantidade de carboidratos.

Objetivos

Objetivo Geral:

O objetivo geral desse trabalho é construir um estimador de carboidratos, que consiste inicialmente na segmentação e classificação de uma imagem contendo um ou mais alimentos. Posteriormente, será feita a reconstrução 3D desse alimento, para cálculo do volume. Dessa forma, será possível estimar a quantidade de carboidratos presente nos alimentos da imagem.

Objetivos Específicos:

No contexto deste trabalho, os objetivos específicos são:

- Levantamento de uma base de dados de imagens contendo alimentos;
- Revisão Bibliográfica sobre técnicas de segmentação, classificação de imagens e reconstrução 3D;
- Implementação de técnicas de segmentação, classificação de imagens e reconstrução 3D;
- Analisar o desempenho dos algoritmos propostos

Metodologia

Inicialmente, foi feita uma busca por bases de dados de imagens públicas de alimentos e de “não alimentos”. Como as bases encontradas estavam confusas,

além de, não atenderem a esse tipo de aplicação, uma base foi capturada manualmente com pesquisa de fotos de conteúdo aberto. Posteriormente, foi realizado o levantamento do material bibliográfico referente às técnicas de agrupamento para segmentação de imagens, segmentação de alimentos, classificação supervisionada de imagens e alimentos. Com o levantamento feito, um conjunto destas técnicas começou a ser implementada.

Foram escolhidos para os testes as técnicas de agrupamento *K-means* e *Fuzzy-C-means* para segmentação dos alimentos e as técnicas de classificação supervisionada com a rede LVQ (*Learning Vector Quantization*) e MLP (*Multi Layer Perceptron*).

Como as técnicas de agrupamento não necessitam de um conjunto de dados de treinamento, inicialmente, optamos por utilizá-las na segmentação de imagens de alimentos. As imagens segmentadas pelas técnicas de agrupamento seriam utilizadas como conjunto de dados para o desenvolvimento de um classificador. Como estas técnicas não apresentaram um desempenho satisfatório, foi necessário gerar um conjunto de dados manualmente para as técnicas de classificação. Neste caso, selecionamos algumas imagens aleatoriamente e retiramos o fundo, de forma que obtivemos apenas um alimento específico nesta imagem. Após a geração de várias imagens contendo apenas determinado alimento ou fundo, foi aplicado técnica de extração de característica. Em seguida as características extraídas foram usadas como entrada para o classificador. Todas as implementações foram desenvolvidas usando o ambiente MATLAB devido ao seu pacote de ferramentas de desenvolvimento gráfico.

Resultados Esperados

Espera-se obter um estimador de carboidratos, que consiga identificar, classificar e estimar o volume dos alimentos com a finalidade de quantificar os carboidratos em uma porção.

Cronograma Previsto Inicialmente

Atividade / Mês	Março	Abril	Mai	Junho	Julho	Agosto	Setembro	Outubro	Novembro
Revisão bibliográfica sobre técnicas de segmentação									
Implementação de algoritmos de segmentação									
Revisão bibliográfica sobre técnicas de classificação									
Implementação de algoritmos de classificação									
Resultados Parciais									
Elaboração do relatório parcial									
Revisão bibliográfica sobre técnicas de reconstrução 3D									
Implementação de algoritmos de reconstrução									
Análise dos resultados obtidos									
Escrita do artigo/monografia									

Atividades realizadas

Como a maioria das bases de dados disponíveis na internet possuem diversos alimentos na mesma imagem ou possuem alimentos que não são de uso cotidiano, decidimos não utilizar e gerar nossa própria base de dados. Foi realizada a busca na internet por algumas imagens de alimentos (alimentos básicos, frutas e doces), tais como, arroz, melancia, brigadeiro, batata e pão. Foram selecionadas 10 imagens contendo somente o alimento em questão. Esta restrição foi adotada para facilitar o treinamento dos modelos a serem gerados. Após a geração destes modelos, serão consideradas imagens contendo diversos alimentos. A figura 1 ilustra algumas das imagens de alimentos selecionados.



Figura 1 Parte da base de dados para cada classe de alimento

Juntamente com a geração da base de alimentos, foi feita uma revisão bibliográfica sobre técnicas de segmentação e de classificação.

As técnicas centrais em visão computacional são sempre relacionadas à análise e processamento de imagens. Os passos que envolvem a análise de imagens são: formação, pré-processamento, segmentação, medição e interpretação. Na parte de segmentação de imagens de alimentos existem apenas duas regiões: o alimento em si e o fundo. Portanto, o resultado é uma imagem binária, contendo “0” ou “1”, ou seja, conseguir separar essas duas regiões. (MERY; PEDRESCHI, 2005)

Porém, em alguns casos é possível segmentar uma imagem sem ter um resultado exato (0 ou 1) e sim múltiplas classes. Os métodos de segmentação *fuzzy* conservam mais informações da imagem original do que métodos de segmentação

rígidos. (PHAM; PRINCE, 1998) O algoritmo *Fuzzy-C-means* classifica um pixel pela probabilidade a qual ele pertence a uma classe.

Especificando a classificação e segmentação de imagens para alimentos, a classificação é considerada difícil. Isso é justificado pela variação da aparência de um alimento, como o formato, textura, cor, entre outras propriedades visuais. Para isso, um passo essencial para resolver esse problema é a extração de características (HE et al, 2013).

Diversas técnicas são usadas para mensurar a textura, como a matriz de co-ocorrência, Fractals, filtros de Gabor, entre outras. A identificação das texturas em uma imagem é obtida a partir de uma matriz que representa a imagem em escalas de cinza. (KEKRE et al, 2010).

Além das técnicas de agrupamento, existem as técnicas de classificação supervisionada. Para a classificação de imagens, são bastante usadas as redes neurais. Um exemplo, é a MLP (*Multi Layer Perceptron*) que treina uma rede utilizando *backpropagation*. Porém, a utilização dessa rede também apresenta problemas. Um dos maiores erros encontrados são com pixels misturados, ou seja, uma área onde cada pixel representa mais de uma classe. Apesar de apresentar problemas, ainda é uma das técnicas mais usadas em alguns casos. (FOODY, 2010)

Após gerada a base de alimentos, alguns experimentos foram realizados usando algoritmos de agrupamento (aprendizado não supervisionado) e algoritmos de classificação (aprendizado supervisionado). O objetivo do emprego das técnicas de agrupamento era automatizar o processo de segmentação dos alimentos sem a necessidade de criar um conjunto de imagens previamente rotuladas. As técnicas de agrupamento utilizadas foram *K-means* e *Fuzzy-C-means*.

No primeiro experimento foi utilizado o valor do pixel em RGB ou escala de cinza como entrada para os algoritmos de agrupamento. Os resultados alcançados para o *K-means* (com K igual a 2) estão ilustrados na figura 2. Como pode ser observado, os resultados não foram satisfatórios. Apesar de algumas imagens terem sido segmentadas corretamente, a grande maioria não foi segmentada corretamente, ficando difícil distinguir os alimentos do fundo da imagem.




Figura 2 K-means com 2 clusters

Na tentativa de melhorar os resultados alcançados com as técnicas de agrupamento, foi realizado um processo de extração de característica. A extração de característica foi realizada usando a Matriz de Co-ocorrência de Níveis de Cinza. A partir desta matriz, foram geradas diversas medidas tais como contraste, energia, entropia, correlação e homogeneidade.

Matriz de Co-ocorrência de Níveis de Cinza (GLCM) é um dos mais antigos métodos de extração de padrões de textura, desenvolvida pelo pesquisador Robert M. Haralick. A matriz é calculada levando em consideração a frequência entre dois pixels (em escala de cinza) dada uma distância e uma orientação (0° , 45° , 90° e 135°) na imagem. Neste processo é considerado um conjunto de valores de pixels e não mais um único valor pixel. A variação dessa distância e da orientação permite que se extraia diferentes padrões de textura da imagem. A figura 3 mostra as possíveis orientações e a figura 4b) mostra a Matriz de Co-ocorrência gerada a partir da imagem mostrada na figura 4a).




Figura 3 Orientação dado um pixel




Figura 4 Geração da Matriz de Co-ocorrência

Como pode ser observado, a matriz de co-ocorrência é quadrada e as posições indicam os níveis de cinza, enquanto os valores das posições indicam a frequência desses pixels na imagem. Nos experimentos realizados, dado um pixel central, foi considerado distância igual a 1, orientação para todos os pixels vizinhos a 0°, 45°, 90°, 135°, 180° e seus complementos. Isto resultou em uma imagem de 5x5 pixels. Neste caso, o pixel central é o pixel que está sendo realizado e todos os pixels a sua volta são considerados pixels vizinhos. Os resultados alcançados com esta técnica de extração foram superiores quando comparados com aqueles obtidos com o valor do pixel. No entanto, estes ainda não conseguiram realizar adequadamente a segmentação de todos os alimentos. Baseado neste fato, experimentos foram realizados usando algoritmos de classificação.

Para gerar os dados de treinamento para a tarefa de classificação, um conjunto de imagens foi gerado contendo apenas o alimento e outras contendo apenas o fundo. Para geração deste conjunto as imagens originais foram recortadas manualmente em sub-imagens contendo apenas o alimento ou fundo. Matriz de Co-ocorrência de Níveis de cinza foi aplicada sobre cada imagem recortada e rotulada de acordo com o alimento em questão ou fundo. Os algoritmos de classificação utilizados foram LVQ (*Learning Vector Quantization*) e Rede Neural MLP (*Multi Layer Perceptron*).

A fim de analisar o comportamento da LVQ foram realizados vários experimentos com diferentes números de épocas (2000, 5000 e 10000 épocas) e diferentes números de neurônios por classe (5, 10, 20 e 30 neurônios). De forma a facilitar o problema de segmentação, a tarefa de classificação consistia de apenas duas classes (classe +1 para um alimento específico e -1 para o fundo da imagem). Os resultados alcançados foram superiores àqueles obtidos via algoritmos de agrupamento. No entanto, para alguns alimentos não foi possível segmentar adequadamente a imagem. Neste caso, alguns detalhes do fundo foram considerados como pertencentes ao alimento.

Inicialmente, os mesmos parâmetros utilizados na LVQ (número de épocas e número de neurônios) foram adotados na MLP. Vale destacar que, neste caso, o número de neurônios na camada intermediária foi o mesmo adotado na LVQ para cada classe. Utilizando apenas uma medida (contraste, energia, entropia, correlação ou homogeneidade) extraída da Matriz de Co-ocorrência foi possível obter um erro quadrático médio (EQM) no treinamento igual a 0.08 usando o contraste, com 10.000 épocas e 30 neurônios. Os resultados são ilustrados na figura 5. A pior medida extraída produziu um EQM igual 0.17.

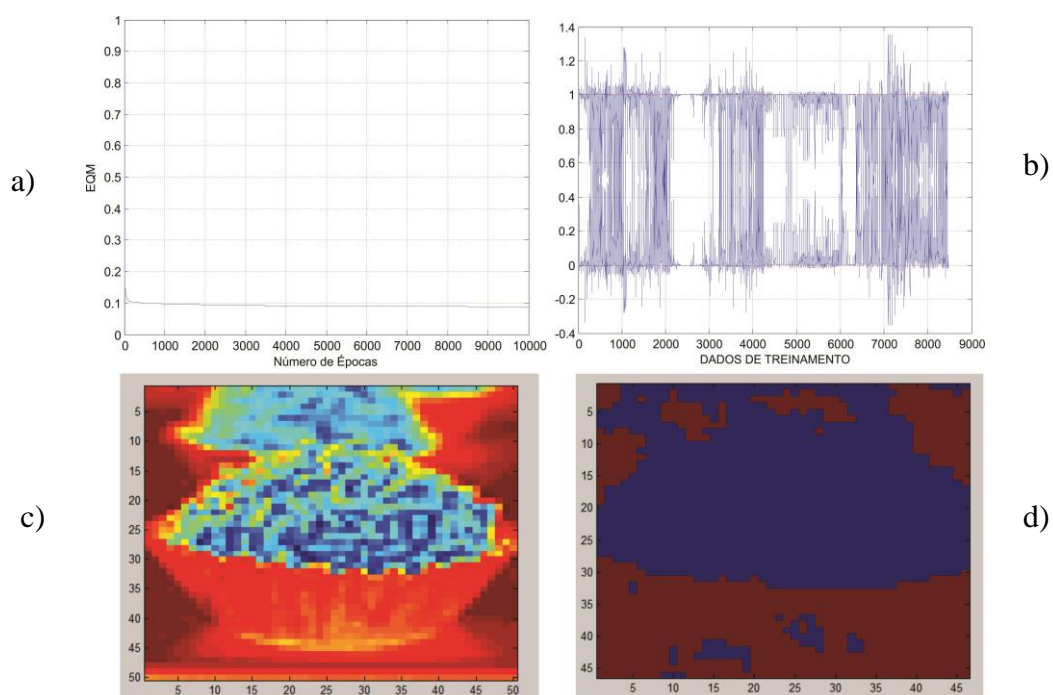


Figura 5 Resultado obtido usando 2 classes, 10.000 épocas e 30 neurônios na camada escondida. a) Evolução do EQM ao longo do treinamento, b) Saída da Rede Neural, c) Imagem original Imagem segmentada, d) Imagem classificada

Visando diminuir o erro obtido no treinamento, foi adicionado a cada um das medidas extraídas, o valor da matriz de cores em RGB do pixel central. Neste caso, usando contraste foi alcançado um EQM igual a 0.02.

Apesar das estratégias anteriores terem produzido um baixo EQM, algumas imagens não foram corretamente segmentadas. Então optou-se por utilizar duas medidas extraídas como entrada para a MLP. Neste caso, foi realizado a combinação duas a duas, adicionando ou não o valor do pixel central. Adotando esta estratégia foi possível alcançar um EQM igual a 0.007, quando usando contraste e energia como entrada para a MLP. Os resultados obtidos são apresentados na Figura 6.

A seguir foi treinada uma MLP para classificar 5 tipos de alimentos diferentes e o fundo. Neste caso, o melhor resultado foi alcançado com um EQM igual a 0.3308 usando a medida de contraste com o valor do pixel central. Os resultados obtidos são apresentados na Figura 7. Analisando os resultados, pode-se dizer que as medidas extraídas da Matriz de Co-ocorrência não são bastante discriminativas para os alimentos considerados. Novas estratégias de extração de características devem ser utilizadas visando alcançar uma discriminação.

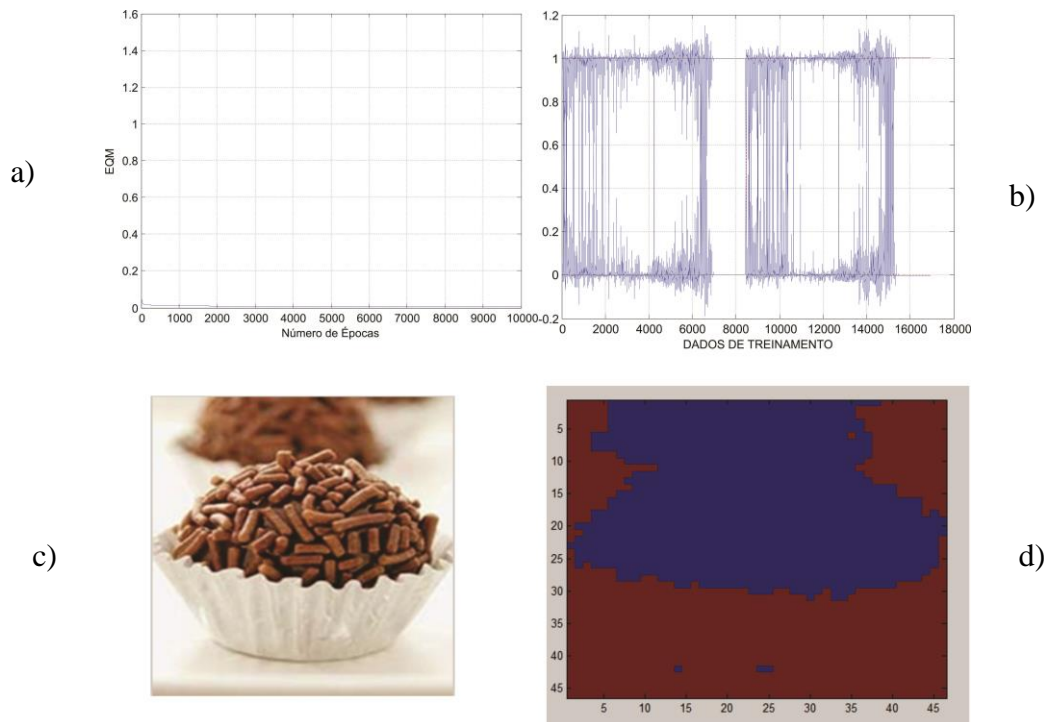


Figura 6 Resultado obtido usando 2 classes, 10.000 épocas, 30 neurônios na camada escondida, contraste e energia como entrada para MLP. a) Evolução do EQM ao longo do treinamento, b) Saída da Rede Neural, c) Imagem original Imagem segmentada, d) Imagem segmentada

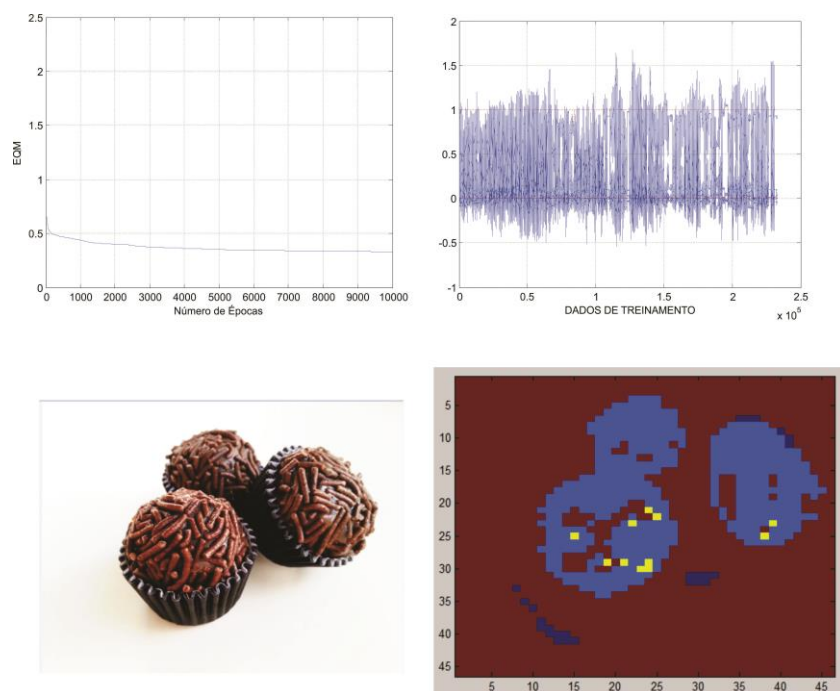


Figura 7 Resultado obtido usando 2 classes, 10.000 épocas, 30 neurônios na camada escondida, contraste e valor do pixel como entrada para MLP. a) Evolução do EQM ao longo do treinamento, b) Saída da Rede Neural, c) Imagem original Imagem segmentada, d) Imagem segmentada

Atividades futuras

As atividades que serão feitas a seguir são:

- Aumentar o número de classes para que o classificador classifique não somente um determinado alimento com um baixo erro, mas todos os alimentos da base de dados com um erro aceitável. Para alcançar este objetivo foi realizado uma pequena alteração no plano de atividades inicial.
- Utilizar a revisão bibliográfica das técnicas de reconstrução 3D para determinar qual a melhor técnica para efetuar a reconstrução dos alimentos.
- Implementar as técnicas de reconstrução 3D escolhidas anteriormente a fim de reconstruir os alimentos classificados.
- Por fim, analisar os dados obtidos e efetuar a escrita de um artigo ou monografia.

Cronograma atualizado

Atividade / Mes	Julho	Agosto	Setembro	Outubro	Novembro
Melhorar erro da classificação com mais classes					
Revisão bibliográfica sobre técnicas de reconstrução 3D					
Implementação de algoritmos de reconstrução					
Análise dos resultados obtidos					
Escrita do artigo/monografia					

Observações sobre outras alterações

Não houve outras alterações.

Referências Bibliográficas

- XU, C.; HE, Y.; KHANNAN, N.; PARRA, A; BOUSHEY, C.; DELP, E.; **Image-based food volume estimation**, in Proceedings of the 5th International Workshop on Multimedia for Cooking & Eating Activities, ser. CEA '13. New York, NY, USA: ACM, 2013, pp. 75-80. [Online]. Disponível em: <http://doi.acm.org/10.1145/2506023.2506037>
- KAGAYA, H.; AIZAWA, K.; OGAWA, M.; **Food detection and recognition using convolutional neural network**, in Proceedings of the ACM International Conference on Multimedia, ser. MM '14. New York, NY, USA: ACM, 2014, pp. 1085-1088. [Online]. Disponível em: <http://doi.acm.org/10.1145/2647868.2654970>
- KEKRE, H.; THEPADE, S.; SARODE, T.; SURYAWANSHI, V.; **Image retrieval using texture features extracted from GLCM, LBG and KPE**.
- HARALICK, R.; SHANMUGAM, K.; DINSTEN, I. **Textural features for image classification**. Systems, Man and Cybernetics, IEEE Transactions on, SMC-3, n. 6, p.610-621, 1973. ISSN 0018-9472
- FOODY, G.; **Supervised image classification by MLP and RBF neural networks with and without an exhaustively defined set of classes**, in International Journal of Remote Sensing, June 2010, pp. 3091-3104.
- SUDO, K.; MURASAKI, K.; SHIMAMURA, J.; TANIGUCHI, Y.; **Estimating nutritional value from food images based on semantic segmentation** in Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing: Adjunct Publication, ser. UbiComp '14 Adjunct. New York, NY, USA: ACM, 2014, pp. 571-576. [Online]. Disponível em: <http://doi.acm.org/10.1145/2638728.2641336>
- PHAM, D.; PRINCE, J.; **An adaptive fuzzy C-means algorithm for image segmentation in the presence of intensity inhomogeneities**, in Pattern Recognition Letters, September 1998, pp. 57-68.
- POULADZADEH, P.; SHIRMOHAMMADI, S.; YASSINE, A.; **Using graph cut segmentation for food calorie measurement**, in Medical Measurements and Applications (MeMeA), 2014 IEEE International Symposium on, June 2014, p. 1-6.

HE, Y.; XU, C.; KHANNA, N.; C, BOUSHEY; E, DELP; **Food image analysis: Segmentation, identification and weight estimation**, in Multimedia and Expo (ICME), 2013 IEEE International Conference on, July 2013, pp. 1-6.

KAWANO, Y.; YANAI, K.; **Real-time mobile food recognition system**, in Computer Vision and Pattern Recognition Workshops (CVPRW), 2013 IEEE Conference on, June 2013, pp. 1-7.

Bibliografia

ASHOK, V.; VINOD, D.; **Automatic quality evaluation of fruits using probabilistic neural network approach**, in Contemporary Computing and Informatics (IC3I), 2014 International Conference on, Nov 2014, pp. 308-311.

AYALA, H.; SANTOS, F.; MARIANI, V.; COELHO, L.; **Image thresholding segmentation based on a novel beta differential evolution approach**, in Expert Systems with Applications, vol. 42, no. 4, pp. 2136 - 2142, 2015. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S095741741400596X>

CABRAL, B.; CAM, N.; FORAN, J.; **Accelerated volume rendering and tomographic reconstruction using texture mapping hardware**, in Proceedings of the 1994 Symposium on Volume Visualization, ser. VVS '94. New York, NY, USA: ACM, 1994, pp. 91{98. [Online]. Available: <http://doi.acm.org/10.1145/197938.197972>

CHEN, M.; YANG, Y.; HO, C.; WANG, S.; LIU, S.; CHANG, E.; YEH, C.; OUHYOUNG, M.; **Automatic chinese food identification and quantity estimation**, in SIGGRAPH Asia 2012 Technical Briefs, ser. SA '12. New York, NY, USA: ACM, 2012, pp. 29:1-29:4. [Online]. Available: <http://doi.acm.org/10.1145/2407746.2407775>

CHEN, Z.; PERNG, D.; **Automatic reconstruction of 3d solid objects from 2d orthographic views**, Pattern Recognition, vol. 21, no. 5, pp. 439 - 449, 1988. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/0031320388900039>

DU, C.; SUN, D.; **Recent developments in the applications of image processing techniques for food quality evaluation**, Trends in Food Science & Technology, vol. 15, no. 5, pp. 230 - 249, 2004. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0924224403002711>

IZADI, S.; KIM, D.; HILLIGES, O.; MOLYNEAUX, D.; NEWCOMBE, R.; KOHLI, P.; SHOTTON, J.; HODGES, S.; FREEMAN, D.; DAVISON, A.; FITZGIBBON, A.; **Kinectfusion: Real-time 3d reconstruction and interaction using a moving depth camera**, in Proceedings of the 24th Annual ACM Symposium on User Interface Software and Technology, ser. UIST '11. New York, NY, USA: ACM, 2011, pp. 559-568. [Online]. Available: <http://doi.acm.org/10.1145/2047196.2047270>

MATEJ, S.; LEWITT, R.; **Efficient 3D grids for image reconstruction using spherically-symmetric volume elements**, Nuclear Science, IEEE Transactions on, vol. 42, no. 4, pp. 1361-1370, Aug 1995.

MERY, D.; PEDRESCHI, F.; **Segmentation of colour food images using a robust algorithm**, Journal of Food Engineering, vol. 66, no. 3, pp. 353 -360, 2005. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0260877404001591>

PENG, R.; VARSHNEY, P.; **A human visual system-driven image segmentation algorithm**, Journal of Visual Communication and Image Representation, vol. 26, no. 0, pp. 66 - 79, 2015. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S1047320314001837>

PENG, R.; **On performance limits of image segmentation algorithms**, Computer Vision and Image Understanding, vol. 132, no. 0, pp. 24-38, 2015. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S1077314214002240>

PHATTARALERPHONG, J.; SINOQUET, H.; **A method for 3d reconstruction of tree crown volume from photographs: assessment with 3d-digitized plants**, Tree Physiology, vol. 25, no. 10, pp. 1229-1242, 2005. [Online]. Available: <http://treephys.oxfordjournals.org/content/25/10/1229.abstract>

PURI, M.; ZHU, Z.; YU, Q.; DIVAKARAN, A.; SAWHNEY, H.; **Recognition and volume estimation of food intake using a mobile device**, in Applications of Computer Vision (WACV), 2009 Workshop on, Dec 2009, pp. 1-8.

SHANG, J.; DUONG, M.; PEPIN, E.; ZHANG, X.; SANDARA-RAJAN, K.; MAMISHEV, A.; KRISTAL, A.; **A mobile structured light system for food volume estimation**, in Computer Vision Workshops (ICCV Workshops), 2011 IEEE International Conference on, Nov 2011, pp. 100-101.

TIAN, X.; JIAO, L.; YI, L.; GUO, K.; ZHANG, X.; **The image segmentation based on optimized spatial feature of super-pixel**, Journal of Visual Communication and Image Representation, vol. 26, no. 0, pp. 146 - 160, 2015. [Online]. Available:

<http://www.sciencedirect.com/science/article/pii/S1047320314001862>

ZHANG, H.; FRITTS, J.; GOLDMAN, S.; **Image segmentation evaluation: A survey of unsupervised methods**, Computer Vision and Image Understanding, vol. 110, no. 2, pp. 260 - 280, 2008. [Online]. Available:

<http://www.sciencedirect.com/science/article/pii/S1077314207001294>

JONES, V.; JONES, P.; JONES, M.; **Robust Real-Time Face Detection**, International Journal of Computer Vision 57, no 2 (1 de maio de 2004): 137–54. [Online]. Available: <http://dx.doi.org/10.1023/B%3AVISI.0000013087.49260.fb>